

Clase 292 — Ataques adversariales a modelos

Parte: **15 — Seguridad de IA y machine learning** · Fuente: *Goodfellow, Shlens & Szegedy, "Explaining and Harnessing Adversarial Examples" (ICLR 2015)* 🕒 Duración estimada: **120 min** · Nivel: **Intermedio**

🎯 Objetivo

Comprender por qué existen los ejemplos adversariales y aprender a generarlos, evaluarlos y defenderlos con herramientas reales. El alumno pasará de la teoría del gradiente (FGSM, PGD) a un ataque práctico sobre un clasificador propio usando Adversarial Robustness Toolbox (ART), y medirá la caída de precisión bajo ataque.

⚠️ **Ética:** los ataques de esta clase se realizan únicamente sobre modelos y datos propios en un laboratorio aislado. Atacar modelos de terceros sin autorización explícita puede ser ilegal.

📊 Resultados de aprendizaje

Al finalizar, el alumno podrá:


1. **Explicar** por qué la linealidad local de las redes profundas produce ejemplos adversariales.
2. **Implementar** ataques FGSM y PGD contra un modelo propio con ART.
3. **Diferenciar** ataques dirigidos/no dirigidos y de caja blanca/negra.
4. **Medir** la robustez con precisión adversarial y una curva de perturbación (ϵ).
5. **Aplicar** entrenamiento adversarial como defensa y evaluar su coste.

📖 Temas

#	Tema	Por qué importa
1	Qué es un ejemplo adversarial	Perturbación mínima que cambia la predicción
2	FGSM: ataque de un paso	Base intuitiva basada en el signo del gradiente
3	PGD: ataque iterativo	Considerado el ataque de referencia (fuerte)
4	Normas de perturbación (L_∞ , L_2 , L_0)	Definen qué significa "imperceptible"
5	Ataques dirigidos vs. no dirigidos	Forzar una clase concreta o solo un error
6	Transferibilidad y caja negra	Un adversarial de un modelo suele engañar a otro
7	Ataques físicos (patches, pegatinas)	La amenaza no vive solo en píxeles digitales
8	Defensas: entrenamiento adversarial	Mejora robustez a costa de precisión limpia

Explicación en profundidad

Un ejemplo adversarial modifica una entrada bajo un modelo de amenaza para cambiar una decisión. Éxito depende de conocimiento, consultas, restricciones y dominio; una perturbación pequeña en píxeles no implica que sea imperceptible o viable físicamente.



El diagrama debe leerse como una cadena de supuestos: verificar un nodo no demuestra los siguientes. La evaluación declara actor, acceso, datos, métrica, umbral y consecuencia; compara una línea base y conserva fallos, no solo promedios.

Caso razonado

Un ataque digital funciona sobre archivos pero no al fotografiar la señal. El informe limita la conclusión al canal probado.

Glosario operativo

Término	Definición
Robustez	Desempeño bajo variaciones definidas, no inmunidad universal.
Evaluación	Experimento reproducible ligado a un riesgo y criterio.
Riesgo residual	Exposición que permanece tras controles.

Criterio de dominio

El alumno demuestra dominio cuando formula un escenario específico, reproduce evidencia, explica límites y diseña controles técnicos y de gobierno sin atribuir certeza al modelo.

Definiciones y características

- **Ejemplo adversarial:** entrada $x' = x + \delta$ con $\|\delta\| \leq \epsilon$ que causa una predicción errónea. *Característica:* δ suele ser imperceptible para un humano.
- **FGSM (Fast Gradient Sign Method):** $x' = x + \epsilon \cdot \text{sign}(\nabla_x J(\theta, x, y))$. *Característica:* un solo paso, rápido pero subóptimo.
- **PGD (Projected Gradient Descent):** FGSM iterado con proyección a la bola de radio ϵ . *Característica:* ataque fuerte, referencia para evaluar defensas.
- **Perturbación L_∞ :** limita el cambio máximo por píxel. *Característica:* la más usada en visión; ϵ típico 8/255.
- **Ataque dirigido:** fuerza una clase objetivo específica; el **no dirigido** solo busca cualquier error.
- **Transferibilidad:** un adversarial generado con un modelo sustituto engaña a otro modelo distinto; habilita ataques de caja negra.
- **Entrenamiento adversarial:** entrenar con ejemplos adversariales generados sobre la marcha (Madry et al.); mejora robustez pero reduce precisión limpia y encarece el entrenamiento.

Herramientas y preparación

```
pip install adversarial-robustness-toolbox torch torchvision numpy matplotlib
```

- **Adversarial Robustness Toolbox (ART)** — ataques y defensas listas para PyTorch/TensorFlow.
- Un modelo propio ya entrenado (p. ej. CNN pequeña sobre MNIST/CIFAR-10). Guarda sus pesos.
- GPU opcional; MNIST corre bien en CPU.

Laboratorio guiado

Todo sobre un **modelo y dataset propios**.

1. **Entrena o carga un clasificador.** Una CNN sobre MNIST alcanza >98% en test limpio. Guarda `model.pt`.

2. **Envuelve el modelo con ART.**

```
python from art.estimators.classification import PyTorchClassifier clf =  
PyTorchClassifier(model=model, loss=loss_fn, input_shape=(1,28,28), nb_classes=10,  
clip_values=(0,1))
```

3. **Mide la precisión limpia** sobre el test set y anótala como línea base.

4. **Genera FGSM.**

```
python from art.attacks.evasion import FastGradientMethod atk =  
FastGradientMethod(estimator=clf, eps=0.2) x_adv = atk.generate(x=x_test)
```

Evalúa la precisión sobre `x_adv`: debería desplomarse.

5. **Genera PGD** (`ProjectedGradientDescent`, `eps=0.2`, `max_iter=40`) y compara: PGD suele ser más efectivo que FGSM con el mismo ϵ .
6. **Barre ϵ .** Repite para $\epsilon \in \{0, 0.05, 0.1, 0.15, 0.2, 0.3\}$ y dibuja la curva precisión vs. ϵ . Observa el compromiso perceptibilidad/eficacia.
7. **Ataque dirigido.** Fuerza que un "3" se clasifique como "8" (`targeted=True`) y verifica visualmente que la imagen sigue pareciendo un 3.
8. **Defiende con entrenamiento adversarial.**

```
python from art.defences.trainer import AdversarialTrainerMadryPGD trainer =  
AdversarialTrainerMadryPGD(clf, eps=0.2) trainer.fit(x_train, y_train)
```

Reevalúa: la precisión adversarial sube, la limpia baja un poco. Documenta el trade-off.

Ejercicios

1. Explica por qué `sign()` del gradiente maximiza la pérdida bajo una restricción L_∞ .
2. Compara la precisión adversarial de FGSM vs. PGD para el mismo ϵ y explica la diferencia.
3. Genera adversariales con un modelo A y evalúalos en un modelo B distinto; mide la transferibilidad.

4. Implementa un ataque L2 (`CarliniL2Method`) y compara la magnitud de perturbación con L_∞ .
5. Muestra 5 pares (original, adversarial) y comenta si un humano notaría la diferencia.
6. Estima cuánto más tarda el entrenamiento adversarial frente al normal y discute si compensa.



Reto verificable

Entrega un **informe de robustez** de tu clasificador con: precisión limpia base, curva precisión vs. ϵ para PGD, un ejemplo dirigido exitoso, y la comparación antes/después de entrenamiento adversarial.

Criterio de aceptación: con entrenamiento adversarial, la precisión bajo PGD ($\epsilon=0.2$) mejora al menos 30 puntos porcentuales respecto al modelo sin defender, y el informe cuantifica explícitamente la caída de precisión limpia asociada. Todo el código es reproducible con `python attack.py`.



Errores comunes

Síntoma / mensaje	Causa y cómo arreglar
El ataque no reduce la precisión	Falta <code>clip_values</code> o el modelo está en modo eval sin gradientes. Verifica el wrapper de ART.
Perturbaciones visibles/feas	ϵ demasiado alto. Baja ϵ y usa PGD iterativo en vez de FGSM.
"Defensa perfecta" con gradient masking	La defensa ofusca gradientes, no aporta robustez real. Evalúa con ataques de caja negra/transferencia.
Precisión limpia se hunde tras defender	ϵ de entrenamiento demasiado alto. Ajusta y busca el punto de equilibrio.
Adversariales no transfieren	Modelos muy distintos o regularización fuerte. Usa un sustituto más parecido.



Preguntas frecuentes

? ¿Por qué existen los ejemplos adversariales? Las redes profundas son localmente casi lineales en dimensiones muy altas; pequeñas perturbaciones alineadas con el gradiente se suman y empujan la salida sobre la frontera de decisión (Goodfellow et al.).

? ¿Sirve la detección de adversariales en lugar de la robustez? Ayuda, pero muchos detectores se rompen ante ataques adaptativos que también engañan al detector. La robustez certificada o el entrenamiento adversarial son más sólidos.

? ¿Esto solo afecta a imágenes? No. Hay adversariales en audio, texto (sustituciones de palabras), malware (bytes que evaden clasificadores) y datos tabulares. El principio del gradiente es el mismo.

? ¿Qué es un ataque físico? Perturbaciones que sobreviven a la captura por cámara: pegatinas en señales de tráfico, patches impresos o monturas de gafas que engañan al reconocimiento facial.



Referencias

- Goodfellow, Shlens & Szegedy, "Explaining and Harnessing Adversarial Examples", ICLR 2015 — <https://arxiv.org/abs/1412.6572>

- Madry et al., "Towards Deep Learning Models Resistant to Adversarial Attacks", ICLR 2018 — <https://arxiv.org/abs/1706.06083>
- Carlini & Wagner, "Towards Evaluating the Robustness of Neural Networks", 2017 — <https://arxiv.org/abs/1608.04644>
- Adversarial Robustness Toolbox — <https://github.com/Trusted-AI/adversarial-robustness-toolbox>
- MITRE ATLAS, técnica "Evade ML Model" — <https://atlas.mitre.org/>



Material descargable

-  [Guía en PDF](#) — versión imprimible de esta clase.
-  [Presentación \(PPTX\)](#) — deck para proyectar en clase.



Clase anterior

Clase 291 — Introducción a la seguridad de IA y ML



Siguiente clase

Clase 293 — Envenenamiento de datos y modelos